

# Projeções de curto prazo para número de hospitalizados por SRAG no drs de Baixada Santista

Baseado nas notificações de SRAG Hospitalizados na base SIVEP Gripe

Observatório COVID-19 BR

28-05-2020\_12h11min36s

## Sumário executivo

- Este relatório usa notificações de casos de SRAG Hospitalizados na base **SIVEP-Gripe** do dia 27 de maio de 2020.
- Nesta base de dados, observamos 1173 casos hospitalizados de **SRAG**. Destes, 257 estão hospitalizados em UTI. Corrigindo para o atraso de notificação, estimamos que o número de hospitalizados está entre 1265 e 2311, e número de casos em UTI está entre 286 e 624.
- No cenário pessimista, utilizando um crescimento **Exponencial**, a projeção para dia 31 de maio do total de casos hospitalizados é de entre 1460 e 3377, e de casos em UTI é de entre 346 e 837.
- No cenário otimista, utilizando um crescimento **Logístico**, a projeção para dia 31 de maio do total de casos hospitalizados é de entre 982 e 2314, e de casos em UTI é de entre 234 e 610.

## Projeções de número total de casos de SRAG hospitalizados

Tabela 1: Projeção do número de casos hospitalizados de SRAG para os próximos 3 dias no cenário pessimista.

Data	Previsto	Limite Inferior	Limite Superior
2020-05-29	1999	1392	3165
2020-05-30	2063	1433	3252
2020-05-31	2113	1460	3377


Tabela 2: Projeção do número de casos hospitalizados de SRAG pra os próximos 3 dias no cenário otimista.

Data	Previsto	Limite Inferior	Limite Superior
2020-05-29	1439	976	2255
2020-05-30	1454	975	2286
2020-05-31	1464	982	2314

## Gráfico das projeções

- Pontos pretos : número de casos hospitalizados observados a cada dia.
- Região e linha vermelha : correção para ao atraso de notificação dos casos hospitalizados. Média e intervalo de confiança de 95%.
- Região azul e linhas pontilhadas : Previsão usando modelos de curto prazo em diferentes cenários. Média e intervalo de confiança de 95%.

### A SRAG – Leitos totais – Exponencial



### B SRAG – Leitos totais – Logístico




Figura 1: Estimativas de crescimento (A) exponencial e (B) logístico para os próximos 3 dias para número de internações por SRAG.

## Projeções de número de casos de SRAG hospitalizados em leitos de UTI

Tabela 3: Projeção do número de casos hospitalizados de SRAG em leitos de UTI para os próximos 3 dias no cenário pessimista.

Data	Previsto	Limite Inferior	Limite Superior
2020-05-29	468	334	788
2020-05-30	484	339	808
2020-05-31	492	346	837


Tabela 4: Projeção do número de casos hospitalizados de SRAG em leitos de UTI pra os próximos 3 dias no cenário otimista.

Data	Previsto	Limite Inferior	Limite Superior
2020-05-29	346	234	593
2020-05-30	350	233	597
2020-05-31	351	234	610

## Gráfico das projeções para número de casos de SRAG hospitalizados em leitos de UTI

- Pontos pretos : número de casos hospitalizados observados a cada dia.
- Região e linha vermelha : correção para ao atraso de notificação dos casos hospitalizados. Média e intervalo de confiança de 95%.
- Região azul e linhas pontilhadas : Previsão usando modelos de curto prazo em diferentes cenários. Média e intervalo de confiança de 95%.

### A SRAG – Leitos UTI – Exponencial



### B SRAG – Leitos UTI – Logístico




Figura 2: Estimativas de crescimento (A) exponencial e (B) logístico para os próximos 3 dias para número de internações em UTI por SRAG.

## Métodos

### Correção do atraso de notificação pelo método de *Nowcasting*

Para corrigir o efeito de atraso da notificação de casos na tabela de notificações, nós utilizamos o método de *nowcasting* descrito em McGough et al. (2019). Esse método utiliza a diferença entre as datas de primeiro sintoma e notificação do caso no banco de dados para estimar o atraso de inclusão de novos casos no sistema de notificação. O pacote NobBS fornece o número de novos casos esperados por dia pelo modelo de atraso nas notificações.

### Tempos de hospitalização em leito comum e UTI

Para modelar a ocupação dos hospitais, nós estimamos a distribuição de tempos entre aparecimento de sintomas e internação, internação e evolução, entrada e saída da UTI, e probabilidade de internação em UTI.

### Estimando número de hospitalizados

O número estimado de hospitalizados por dia é dado pelos indivíduos notificados na tabela original do Sivep-Gripe + indivíduos não-observados mas esperados pelo *nowcast*, que são incluídos na tabela com datas de entrada e evolução simuladas a partir das distribuições de tempos. Esse modelo permite uma avaliação dinâmica da curva de hospitalizações já corrigida pelo atraso de notificação e tempos de permanência no hospital.

### Projeções de curto prazo utilizando modelos estatísticos

Para realizar as projeções de curto prazo, nós ajustamos duas curvas ao número de casos hospitalizados. As curvas representam cenários diferentes: uma curva exponencial generalizada, que é adequada para modelar o começo de uma epidemia, com crescimento rápido, sendo portanto um cenário pessimista; e uma curva logística generalizada, que apresenta um crescimento que se desacelera com o tempo, representando um cenário otimista. Ambos os modelos são descritos em Wu et al. (2020).

Os modelos usados são dados pelas seguintes equações diferenciais, nas quais  $C(t)$  representa o número de hospitalizados, e os parâmetros são definidos como:  $r$  taxa de crescimento,  $p$  parâmetro de modulação do crescimento (pode variar entre 0 e 1, valores mais baixos correspondem a curvas de crescimento mais lento), e, no caso da logística,  $K$ , um parâmetro de assíntota da curva.

- Exponencial generalizada:

$$\frac{dC(t)}{dt} = rC(t)^p$$

- Logística generalizada:

$$\frac{dC(t)}{dt} = rC(t)^p \left( 1 - \frac{C(t)}{K} \right)$$

### Limitações

- O método de *nowcasting* utilizado assume que a dinâmica de inclusão de novos casos no banco de dados é parecida com o passado. Se o atraso de inclusão aumenta muito, o modelo vai subestimar quantidade de novos casos. O mesmo se aplica aos modelos de distribuição dos tempos de hospitalização e probabilidade de internação em UTI.
- As previsões de curto prazo utilizam curvas fenomenológicas que não se prestam a previsões de longo prazo, portanto não são adequadas para prever a dinâmica da epidemia numa escala de tempo maior. Em particular, o uso de uma curva logística não implica que uma assíntota no número de hospitalizações é sugerida pelos dados.

## Referências

McGough, Sarah , Michael A. Johansson, Marc Lipsitch, Nicolas A. Menzies(2019). Nowcasting by Bayesian Smoothing: A flexible, generalizable model for real-time epidemic tracking. bioRxiv 663823; doi: <https://doi.org/10.1101/663823>

McGough, Sarah, Nicolas Menzies, Marc Lipsitch and Michael Johansson (2020). NobBS: Nowcasting by Bayesian Smoothing. R package version 0.1.0. <https://CRAN.R-project.org/package=NobBS>

Wu, Ke, Didier Darcet, Qian Wang, and Didier Sornette (2020). Generalized Logistic Growth Modeling of the COVID-19 Outbreak in 29 Provinces in China and in the Rest of the World. arXiv [q-bio.PE]. arXiv. <http://arxiv.org/abs/2003.05681>.

## Observatório COVID-19 BR

O Observatório Covid-19 BR é uma iniciativa independente, fruto da colaboração entre pesquisadores com o desejo de contribuir para a disseminação de informação de qualidade baseada em dados atualizados e análises cientificamente embasadas.

Criamos um sítio com códigos de fonte aberta que nos permite acompanhar o estado atual da epidemia de Covid-19 no Brasil, incluindo análises estatísticas e previsões. Modelos estatísticos e matemáticos para previsões da epidemia estão em preparação

**Site:** <https://covid19br.github.io/>

**Contato:** [obscovid19br@gmail.com](mailto:obscovid19br@gmail.com)

## Comparação com previsões anteriores

Validação das previsões usando a base do dia 2020-05-25  
contra observados atuais

