

# Projeções de curto prazo para número de hospitalizados por SRAG no município de São Paulo

Baseado nas notificações de SRAG Hospitalizados na base SIVEP Gripe

Observatório COVID-19 BR

27-04-2020\_14h57min44s

## Sumário executivo

- Este relatório usa notificações de casos de SRAG Hospitalizados na base **SIVEP-Gripe** do dia 27 de abril de 2020.
- Nesta base de dados, observamos 11646 casos hospitalizados de **SRAG**. Destes, 3178 estão hospitalizados em UTI. Corrigindo para o atraso de notificação, estimamos que o número de hospitalizados está entre 12188 e 13931, e número de casos em UTI está entre 3330 e 3836.
- No cenário pessimista, utilizando um crescimento **Exponencial**, a projeção para dia 03 de maio do total de casos hospitalizados é de entre 16698 e 28964, e de casos em UTI é de entre 4376 e 7473.
- No cenário otimista, utilizando um crescimento **Logístico**, a projeção para dia 03 de maio do total de casos hospitalizados é de entre 10090 e 15405, e de casos em UTI é de entre 2806 e 4265.

## Projeções de número total de casos de SRAG hospitalizados

Tabela 1: Projeção do número de casos hospitalizados de SRAG para os próximos 6 dias no cenário pessimista.

Data	Previsto	Limite Inferior	Limite Superior
2020-04-28	18313	13765	23819
2020-04-29	19050	14305	24668
2020-04-30	19742	14930	25859
2020-05-01	20673	15497	27094
2020-05-02	21511	15768	27810
2020-05-03	22334	16698	28964


Tabela 2: Projeção do número de casos hospitalizados de SRAG pra os próximos 6 dias no cenário otimista.

Data	Previsto	Limite Inferior	Limite Superior
2020-04-28	12108	9949	15043
2020-04-29	12258	10035	15159
2020-04-30	12351	10056	15186
2020-05-01	12352	10067	15188
2020-05-02	12408	10111	15344
2020-05-03	12471	10090	15405

## Gráfico das projeções

- Pontos pretos : número de casos hospitalizados observados a cada dia.
- Região e linha vermelha : correção para ao atraso de notificação dos casos hospitalizados. Média e intervalo de confiança de 95%.
- Região azul e linhas pontilhadas : Previsão usando modelos de curto prazo em diferentes cenários. Média de intervalo de confiança de 95%.

### A SRAG – Leitos totais – Exponencial



### B SRAG – Leitos totais – Logístico




Figura 1: Estimativas de crescimento (A) exponencial e (B) logístico para os próximos 6 dias para número de internações por SRAG.

## Projeções de número de casos de SRAG hospitalizados em leitos de UTI

Tabela 3: Projeção do número de casos hospitalizados de SRAG em leitos de UTI para os próximos 6 dias no cenário pessimista.

Data	Previsto	Limite Inferior	Limite Superior
2020-04-28	4935	3688	6322
2020-04-29	5122	3828	6530
2020-04-30	5288	3972	6722
2020-05-01	5454	4111	6968
2020-05-02	5645	4216	7219
2020-05-03	5798	4376	7473

Tabela 4: Projeção do número de casos hospitalizados de SRAG em leitos de UTI pra os próximos 6 dias no cenário otimista.

Data	Previsto	Limite Inferior	Limite Superior
2020-04-28	3386	2758	4170
2020-04-29	3404	2785	4179
2020-04-30	3408	2774	4218
2020-05-01	3427	2794	4228
2020-05-02	3435	2816	4247
2020-05-03	3443	2806	4265

## Gráfico das projeções para número de casos de SRAG hospitalizados em leitos de UTI

- Pontos pretos : número de casos hospitalizados observados a cada dia.
- Região e linha vermelha : correção para ao atraso de notificação dos casos hospitalizados. Média e intervalo de confiança de 95%.
- Região azul e linhas pontilhadas : Previsão usando modelos de curto prazo em diferentes cenários. Média e intervalo de confiança de 95%.

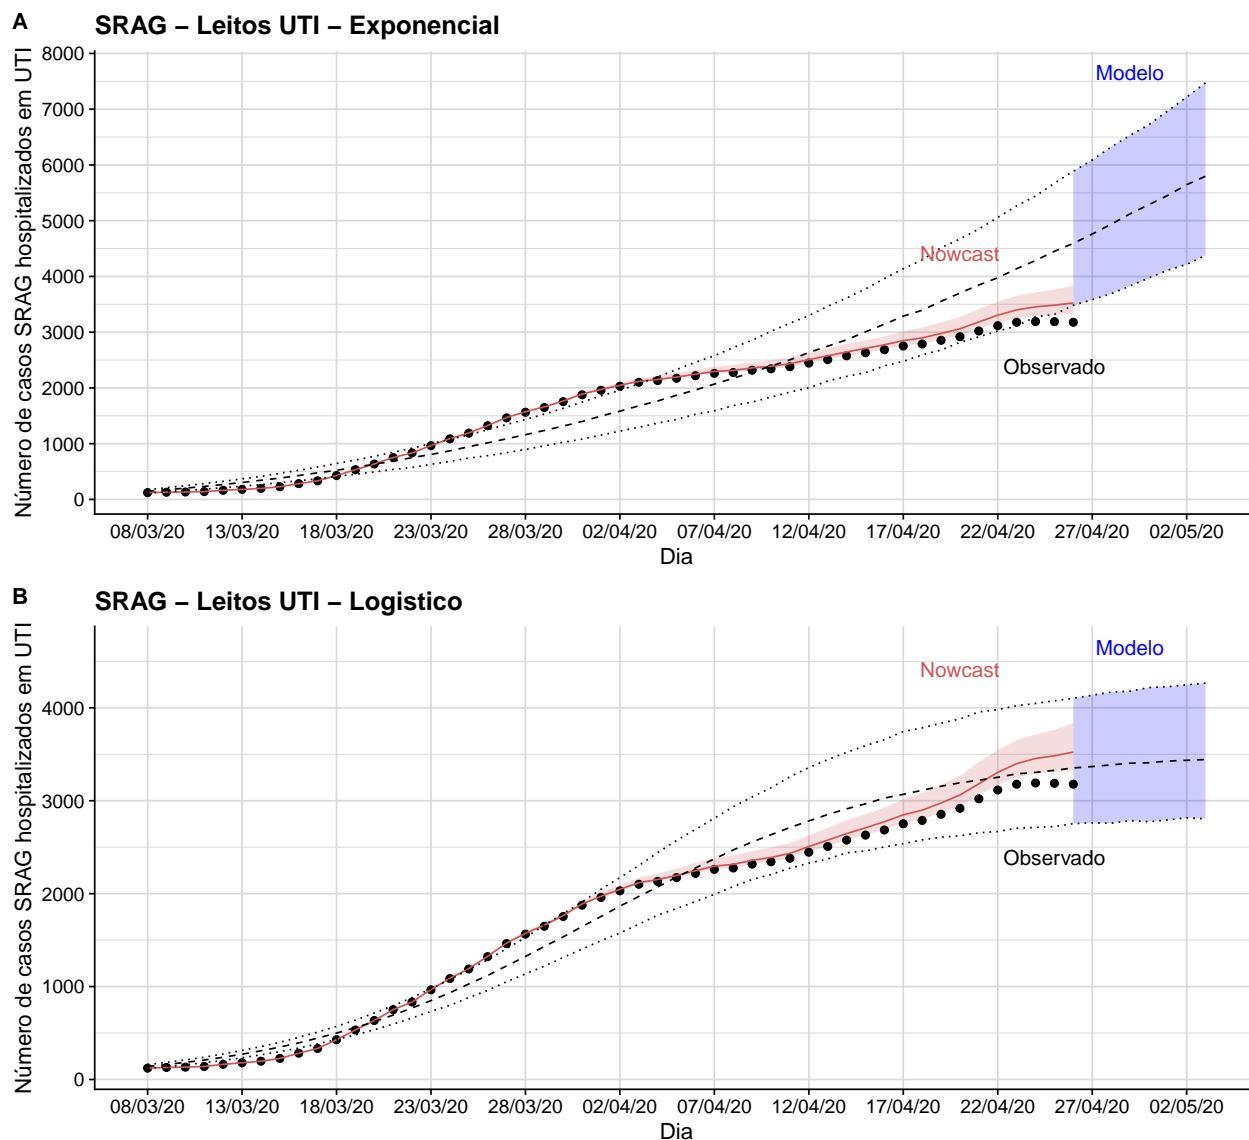


Figura 2: Estimativas de crescimento (A) exponencial e (B) logístico para os próximos 6 dias para número de internações em UTI por SRAG.

## Métodos

### Correção do atraso de notificação pelo método de *Nowcasting*

Para corrigir o efeito de atraso da notificação de casos na tabela de notificações, nós utilizamos o método de *nowcasting* descrito em McGough et al. (2019). Esse método utiliza a diferença entre as datas de primeiro sintoma e notificação do caso no banco de dados para estimar o atraso de inclusão de novos casos no sistema de notificação. O pacote NobBS fornece o número de novos casos esperados por dia pelo modelo de atraso nas notificações.

### Tempos de hospitalização em leito comum e UTI

Para modelar a ocupação dos hospitais, nós estimamos a distribuição de tempos entre aparecimento de sintomas e internação, internação e evolução, entrada e saída da UTI, e probabilidade de internação em UTI.

### Estimando número de hospitalizados

O número estimado de hospitalizados por dia é dado pelos indivíduos notificados na tabela original do Sivep-Gripe + indivíduos não-observados mas esperados pelo *nowcast*, que são incluídos na tabela com datas de entrada e evolução simuladas a partir das distribuições de tempos. Esse modelo permite uma avaliação dinâmica da curva de hospitalizações já corrigida pelo atraso de notificação e tempos de permanência no hospital.

### Projeções de curto prazo utilizando modelos estatísticos

Para realizar as projeções de curto prazo, nós ajustamos duas curvas ao número de casos hospitalizados. As curvas representam cenários diferentes: uma curva exponencial generalizada, que é adequada para modelar o começo de uma epidemia, com crescimento rápido, sendo portanto um cenário pessimista; e uma curva logística generalizada, que apresenta um crescimento que se desacelera com o tempo, representando um cenário otimista. Ambos os modelos são descritos em Wu et al. (2020).

Os modelos usados são dados pelas seguintes equações diferenciais, nas quais  $C(t)$  representa o número de hospitalizados, e os parâmetros são definidos como:  $r$  taxa de crescimento,  $p$  parâmetro de modulação do crescimento (pode variar entre 0 e 1, valores mais baixos correspondem a curvas de crescimento mais lento), e, no caso da logística,  $K$ , um parâmetro de assíntota da curva.

- Exponencial generalizada:

$$\frac{dC(t)}{dt} = rC(t)^p$$

- Logística generalizada:

$$\frac{dC(t)}{dt} = rC(t)^p \left( 1 - \frac{C(t)}{K} \right)$$

### Limitações

- O método de *nowcasting* utilizado assume que a dinâmica de inclusão de novos casos no banco de dados é parecida com o passado. Se o atraso de inclusão aumenta muito, o modelo vai subestimar quantidade de novos casos. O mesmo se aplica aos modelos de distribuição dos tempos de hospitalização e probabilidade de internação em UTI.
- As previsões de curto prazo utilizam curvas fenomenológicas que não se prestam a previsões de longo prazo, portanto não são adequadas para prever a dinâmica da epidemia numa escala de tempo maior. Em particular, o uso de uma curva logística não implica que uma assíntota no número de hospitalizações é sugerida pelos dados.

## Referências

McGough, Sarah , Michael A. Johansson, Marc Lipsitch, Nicolas A. Menzies(2019). Nowcasting by Bayesian Smoothing: A flexible, generalizable model for real-time epidemic tracking. bioRxiv 663823; doi: <https://doi.org/10.1101/663823>

McGough, Sarah, Nicolas Menzies, Marc Lipsitch and Michael Johansson (2020). NobBS: Nowcasting by Bayesian Smoothing. R package version 0.1.0. <https://CRAN.R-project.org/package=NobBS>

Wu, Ke, Didier Darcet, Qian Wang, and Didier Sornette (2020). Generalized Logistic Growth Modeling of the COVID-19 Outbreak in 29 Provinces in China and in the Rest of the World. arXiv [q-bio.PE]. arXiv. <http://arxiv.org/abs/2003.05681>.

## Observatório COVID-19 BR

O Observatório Covid-19 BR é uma iniciativa independente, fruto da colaboração entre pesquisadores com o desejo de contribuir para a disseminação de informação de qualidade baseada em dados atualizados e análises cientificamente embasadas.





Criamos um sítio com códigos de fonte aberta que nos permite acompanhar o estado atual da epidemia de Covid-19 no Brasil, incluindo análises estatísticas e previsões. Modelos estatísticos e matemáticos para previsões da epidemia estão em preparação

**Site:** <https://covid19br.github.io/>





**Contato:** [obscovid19br@gmail.com](mailto:obscovid19br@gmail.com)

## Comparação com previsões anteriores

Validação das previsões usando a base do dia 2020-04-26  
contra observados atuais







**Validação das previsões usando a base do dia 2020-04-25  
contra observados atuais**













**Validação das previsões usando a base do dia 2020-04-24  
contra observados atuais**







**Validação das previsões usando a base do dia 2020-04-23  
contra observados atuais**



**Validação das previsões usando a base do dia 2020-04-22  
contra observados atuais**



**Validação das previsões usando a base do dia 2020-04-21  
contra observados atuais**



**Validação das previsões usando a base do dia 2020-04-20  
contra observados atuais**

