

# Projeções de curto prazo para número de hospitalizados por SRAG no município de São Paulo

Baseado nas notificações de SRAG Hospitalizados na base SIVEP Gripe

Observatório COVID-19 BR

29-04-2020\_21h13min19s

## Sumário executivo

- Este relatório usa notificações de casos de SRAG Hospitalizados na base **SIVEP-Gripe** do dia 29 de abril de 2020.
- Nesta base de dados, observamos 12675 casos hospitalizados de **SRAG**. Destes, 3366 estão hospitalizados em UTI. Corrigindo para o atraso de notificação, estimamos que o número de hospitalizados está entre 13370 e 15117, e número de casos em UTI está entre 3523 e 4054.
- No cenário pessimista, utilizando um crescimento **Exponencial**, a projeção para dia 05 de maio do total de casos hospitalizados é de entre 16921 e 28683, e de casos em UTI é de entre 4353 e 7234.
- No cenário otimista, utilizando um crescimento **Logístico**, a projeção para dia 05 de maio do total de casos hospitalizados é de entre 10731 e 16440, e de casos em UTI é de entre 2928 e 4426.

## Projeções de número total de casos de SRAG hospitalizados

Tabela 1: Projeção do número de casos hospitalizados de SRAG para os próximos 6 dias no cenário pessimista.

Data	Previsto	Limite Inferior	Limite Superior
2020-04-30	18627	14248	23714
2020-05-01	19444	14829	24756
2020-05-02	20099	15084	25714
2020-05-03	20922	15712	26708
2020-05-04	21641	16321	27643
2020-05-05	22435	16921	28683


Tabela 2: Projeção do número de casos hospitalizados de SRAG pra os próximos 6 dias no cenário otimista.

Data	Previsto	Limite Inferior	Limite Superior
2020-04-30	12826	10517	15880
2020-05-01	12898	10515	15984
2020-05-02	12933	10589	16099
2020-05-03	13034	10657	16280
2020-05-04	13100	10632	16361
2020-05-05	13159	10731	16440

## Gráfico das projeções

- Pontos pretos : número de casos hospitalizados observados a cada dia.
- Região e linha vermelha : correção para ao atraso de notificação dos casos hospitalizados. Média e intervalo de confiança de 95%.
- Região azul e linhas pontilhadas : Previsão usando modelos de curto prazo em diferentes cenários. Média de intervalo de confiança de 95%.

**A** SRAG – Leitos totais – Exponencial



**B** SRAG – Leitos totais – Logístico




Figura 1: Estimativas de crescimento (A) exponencial e (B) logístico para os próximos 6 dias para número de internações por SRAG.

## Projeções de número de casos de SRAG hospitalizados em leitos de UTI

Tabela 3: Projeção do número de casos hospitalizados de SRAG em leitos de UTI para os próximos 6 dias no cenário pessimista.

Data	Previsto	Limite Inferior	Limite Superior
2020-04-30	4958	3787	6239
2020-05-01	5138	3900	6437
2020-05-02	5294	4034	6603
2020-05-03	5478	4178	6865
2020-05-04	5598	4298	7073
2020-05-05	5775	4353	7234

Tabela 4: Projeção do número de casos hospitalizados de SRAG em leitos de UTI pra os próximos 6 dias no cenário otimista.

Data	Previsto	Limite Inferior	Limite Superior
2020-04-30	3512	2887	4332
2020-05-01	3549	2867	4348
2020-05-02	3559	2896	4367
2020-05-03	3587	2910	4372
2020-05-04	3598	2924	4411
2020-05-05	3599	2928	4426

## Gráfico das projeções para número de casos de SRAG hospitalizados em leitos de UTI

- Pontos pretos : número de casos hospitalizados observados a cada dia.
- Região e linha vermelha : correção para ao atraso de notificação dos casos hospitalizados. Média e intervalo de confiança de 95%.
- Região azul e linhas pontilhadas : Previsão usando modelos de curto prazo em diferentes cenários. Média e intervalo de confiança de 95%.




Figura 2: Estimativas de crescimento (A) exponencial e (B) logístico para os próximos 6 dias para número de internações em UTI por SRAG.

## Métodos

### Correção do atraso de notificação pelo método de *Nowcasting*

Para corrigir o efeito de atraso da notificação de casos na tabela de notificações, nós utilizamos o método de *nowcasting* descrito em McGough et al. (2019). Esse método utiliza a diferença entre as datas de primeiro sintoma e notificação do caso no banco de dados para estimar o atraso de inclusão de novos casos no sistema de notificação. O pacote NobBS fornece o número de novos casos esperados por dia pelo modelo de atraso nas notificações.

### Tempos de hospitalização em leito comum e UTI

Para modelar a ocupação dos hospitais, nós estimamos a distribuição de tempos entre aparecimento de sintomas e internação, internação e evolução, entrada e saída da UTI, e probabilidade de internação em UTI.

### Estimando número de hospitalizados

O número estimado de hospitalizados por dia é dado pelos indivíduos notificados na tabela original do Sivep-Gripe + indivíduos não-observados mas esperados pelo *nowcast*, que são incluídos na tabela com datas de entrada e evolução simuladas a partir das distribuições de tempos. Esse modelo permite uma avaliação dinâmica da curva de hospitalizações já corrigida pelo atraso de notificação e tempos de permanência no hospital.

### Projeções de curto prazo utilizando modelos estatísticos

Para realizar as projeções de curto prazo, nós ajustamos duas curvas ao número de casos hospitalizados. As curvas representam cenários diferentes: uma curva exponencial generalizada, que é adequada para modelar o começo de uma epidemia, com crescimento rápido, sendo portanto um cenário pessimista; e uma curva logística generalizada, que apresenta um crescimento que se desacelera com o tempo, representando um cenário otimista. Ambos os modelos são descritos em Wu et al. (2020).

Os modelos usados são dados pelas seguintes equações diferenciais, nas quais  $C(t)$  representa o número de hospitalizados, e os parâmetros são definidos como:  $r$  taxa de crescimento,  $p$  parâmetro de modulação do crescimento (pode variar entre 0 e 1, valores mais baixos correspondem a curvas de crescimento mais lento), e, no caso da logística,  $K$ , um parâmetro de assíntota da curva.

- Exponencial generalizada:

$$\frac{dC(t)}{dt} = rC(t)^p$$

- Logística generalizada:

$$\frac{dC(t)}{dt} = rC(t)^p \left( 1 - \frac{C(t)}{K} \right)$$

### Limitações

- O método de *nowcasting* utilizado assume que a dinâmica de inclusão de novos casos no banco de dados é parecida com o passado. Se o atraso de inclusão aumenta muito, o modelo vai subestimar quantidade de novos casos. O mesmo se aplica aos modelos de distribuição dos tempos de hospitalização e probabilidade de internação em UTI.
- As previsões de curto prazo utilizam curvas fenomenológicas que não se prestam a previsões de longo prazo, portanto não são adequadas para prever a dinâmica da epidemia numa escala de tempo maior. Em particular, o uso de uma curva logística não implica que uma assíntota no número de hospitalizações é sugerida pelos dados.

## Referências

McGough, Sarah , Michael A. Johansson, Marc Lipsitch, Nicolas A. Menzies(2019). Nowcasting by Bayesian Smoothing: A flexible, generalizable model for real-time epidemic tracking. bioRxiv 663823; doi: <https://doi.org/10.1101/663823>

McGough, Sarah, Nicolas Menzies, Marc Lipsitch and Michael Johansson (2020). NobBS: Nowcasting by Bayesian Smoothing. R package version 0.1.0. <https://CRAN.R-project.org/package=NobBS>

Wu, Ke, Didier Darcet, Qian Wang, and Didier Sornette (2020). Generalized Logistic Growth Modeling of the COVID-19 Outbreak in 29 Provinces in China and in the Rest of the World. arXiv [q-bio.PE]. arXiv. <http://arxiv.org/abs/2003.05681>.

## Observatório COVID-19 BR

O Observatório Covid-19 BR é uma iniciativa independente, fruto da colaboração entre pesquisadores com o desejo de contribuir para a disseminação de informação de qualidade baseada em dados atualizados e análises cientificamente embasadas.





Criamos um sítio com códigos de fonte aberta que nos permite acompanhar o estado atual da epidemia de Covid-19 no Brasil, incluindo análises estatísticas e previsões. Modelos estatísticos e matemáticos para previsões da epidemia estão em preparação

**Site:** <https://covid19br.github.io/>





**Contato:** [obscovid19br@gmail.com](mailto:obscovid19br@gmail.com)

## Comparação com previsões anteriores

Validação das previsões usando a base do dia 2020-04-28  
contra observados atuais







**Validação das previsões usando a base do dia 2020-04-27  
contra observados atuais**













**Validação das previsões usando a base do dia 2020-04-26  
contra observados atuais**







**Validação das previsões usando a base do dia 2020-04-25  
contra observados atuais**



**Validação das previsões usando a base do dia 2020-04-24  
contra observados atuais**



**Validação das previsões usando a base do dia 2020-04-23  
contra observados atuais**



**Validação das previsões usando a base do dia 2020-04-22  
contra observados atuais**

